

2 順伝播型ネットワーク

ニューラルネットワークを定式化

2.1 ユニットの出力

キーワード

順伝播型 (ニューラル) ネットワーク, 多層パーセプトロン, 重み, バイアス, 活性化関数

ネットワークを構成する各ユニットは, 入力 x_1, \dots, x_I を受けとり, 総入力:

$$u = w_1 x_1 + \dots + w_I x_I + b \quad (1)$$

を計算した上で, 活性化関数 f を用いて

$$z = f(u) \quad (2)$$

を出力します. ここで w_1, \dots, w_I は重み, b はバイアスです.

1 つの層に複数のユニットが存在している場合, ベクトルを用いて次のように書けます.

$$\mathbf{u} = \mathbf{W}\mathbf{x} + \mathbf{b} \quad (3)$$

$$\mathbf{z} = \mathbf{f}(\mathbf{u}) \quad (4)$$

ただし, 入力 (=第一層) のユニット数は I , 第二層のユニット数は J とし, 各記号は次のとおり:

$$\mathbf{u} = (u_1, \dots, u_J)^\top, \mathbf{x} = (x_1, \dots, x_I)^\top, \mathbf{b} = (b_1, \dots, b_J)^\top, \mathbf{z} = (z_1, \dots, z_J)^\top, \quad (5)$$

$$\mathbf{W} = \begin{pmatrix} w_{11} & \dots & w_{1I} \\ \vdots & \ddots & \vdots \\ w_{J1} & \dots & w_{JI} \end{pmatrix}, \mathbf{f}(\mathbf{u}) = (f(u_1), \dots, f(u_J))^\top \quad (6)$$

2.2 活性化関数 (ユニット間, 出力層ではない)

キーワード

ロジスティック (シグモイド) 関数, シグモイド関数, 正規化線形関数, マックスアウト

- ロジスティック関数 \subset シグモイド関数

$$f(u) = \frac{1}{1 + e^{-u}} \quad (7)$$

- 双曲線正接関数 (hyperbolic tangent) \subset シグモイド関数

$$f(u) = \tanh(u) \quad (8)$$

- 正規化線形関数

$$f(u) = \max(u, 0) \quad (9)$$

この関数をもつユニットを **ReLU** と言います.

- 線形写像・恒等写像

- ロジスティック関数を区分線形近似したもの

$$f(u) = \begin{cases} -1 & u < -1 \\ u & -1 \leq u < 1 \\ 1 & u \geq 1 \end{cases} \quad (10)$$

- マックスアウト (K 個のユニットをまとめたようなもの)

$$u_{jk} = \sum_i w_{jik} z_i + b_{jk} \quad (11)$$

$$f(u_j) = \max_{k=1, \dots, K} u_{jk} \quad (12)$$

2.3 多層ネットワーク

キーワード

入力層, 中間層 (=隠れ層), 出力層

各層のユニットの入出力の計算を区別するために, 層が $l = 1, 2, \dots, L$ となっているときに各変数の肩に (l) と記すことにします. すると, 層 2 のユニットの出力 $\mathbf{z}^{(2)}$ は, 入力層 \mathbf{x} から

$$\mathbf{u}^{(2)} = \mathbf{W}^{(2)}\mathbf{x} + \mathbf{b}^{(2)} \quad (13)$$

$$\mathbf{z}^{(2)} = \mathbf{f}(\mathbf{u}^{(2)}) \quad (14)$$

と計算され, その後の層 $l+1$ のユニットの出力 $\mathbf{z}^{(l+1)}$ は, 1 つ下の層の出力 $\mathbf{z}^{(l)}$ から

$$\mathbf{u}^{(l+1)} = \mathbf{W}^{(l+1)}\mathbf{z}^{(l)} + \mathbf{b}^{(l+1)} \quad (15)$$

$$\mathbf{z}^{(l+1)} = \mathbf{f}(\mathbf{u}^{(l+1)}) \quad (16)$$

と計算される. 最後に層 L まで計算が終わったら, ネットワークの最終的な出力を

$$\mathbf{y} = \mathbf{z}^{(L)} \quad (17)$$

と表記する. 各層の重み $\mathbf{W}^{(l)}$ とバイアス $\mathbf{b}^{(l)}$ をユニットのパラメータと呼び, 出力 \mathbf{y} は入力とパラメータによって決まることから,

$$\mathbf{y}(\mathbf{x}; \mathbf{W}^{(2)}, \dots, \mathbf{W}^{(L)}, \mathbf{b}^{(2)}, \dots, \mathbf{b}^{(L)}) \quad (18)$$

あるいは簡単に

$$\mathbf{y}(\mathbf{x}; \mathbf{w}) \quad (19)$$

と書きます.

2.4 出力層の設計と誤算関数

キーワード

訓練サンプル, 訓練データ, 誤算関数, 回帰, 二値分類, 多クラス分類, 最尤推定, ソフトマックス関数, 交差エントロピー

学習に使用する入出力データのペア

$$\{(\mathbf{x}_1, \mathbf{d}_1), (\mathbf{x}_2, \mathbf{d}_2), \dots, (\mathbf{x}_N, \mathbf{d}_N)\} \quad (20)$$

を訓練データといいます.

2.4.1 回帰

出力層の活性化関数には恒等写像を用い、誤算関数には二乗誤算の和

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \|\mathbf{d}_n - \mathbf{y}(\mathbf{x}_n; \mathbf{w})\|^2 \quad (21)$$

を使用し、 $E(\mathbf{w})$ がもっとも小さくなる \mathbf{w} を求める。

2.4.2 二値分類

ここでは \mathbf{x} を指定したときに $d = 1$ となる事後確率 $p(d = 1|\mathbf{x})$ を、ネットワーク全体の出力 $y(\mathbf{x}; \mathbf{w})$ でモデル化し、出力層の活性化関数にロジスティック関数を使うことで、

$$p(d = 1|\mathbf{x}) \approx y(\mathbf{x}; \mathbf{w}) \quad (22)$$

とします。パラメータ \mathbf{w} は最尤推定で求めることにします。 $p(d = 1|\mathbf{x}) = y(\mathbf{x}; \mathbf{w})$ より $p(d = 0|\mathbf{x}) = 1 - y(\mathbf{x}; \mathbf{w})$ であることと、

$$p(d|\mathbf{x}) = p(d = 1|\mathbf{x})^d p(d = 0|\mathbf{x})^{1-d} \quad (23)$$

より、 N 個の入力に対する尤度は

$$L(\mathbf{w}) = \prod_{n=1}^N p(d_n|\mathbf{x}_n; \mathbf{w}) = \prod_{n=1}^N y(\mathbf{x}_n; \mathbf{w})^{d_n} \{1 - y(\mathbf{x}_n; \mathbf{w})\}^{1-d_n} \quad (24)$$

となります。誤差関数としてはこれに対数をとって符号を反転させた

$$E(\mathbf{w}) = - \sum_{n=1}^N [d_n \log y(\mathbf{x}_n; \mathbf{w}) + (1 - d_n) \log \{1 - y(\mathbf{x}_n; \mathbf{w})\}] \quad (25)$$

を用て、パラメータ \mathbf{w} を求めます。

2.4.3 多クラス分類

ネットワークの出力層にクラス数 K と同じ K 個のユニットを並べ、出力層の各ユニット $k(= 1, \dots, K)$ の出力を

$$y_k = z_k^{(L)} = \frac{\exp(u_k^{(L)})}{\sum_{j=1}^K \exp(u_j^{(L)})} \quad (26)$$

とします。